

Curso: Machine Learning (CS3061)

Proyecto 2: Clasificación de Señales Eco-Acústicas

Prof. D.Sc. Manuel Eduardo Loaiza Fernandez
ACL. Abel Escóbar Pérez

1. Introducción y Objetivos

El presente proyecto aborda la clasificación automatizada de señales eco-acústicas para la identificación autónoma de especies faunísticas a partir de datos tabulares preprocesados. El objetivo principal es el desarrollo de un pipeline integral de Machine Learning que abarque la exploración geométrica, la reducción de dimensionalidad ($X \in \mathbb{R}^{64}$), el agrupamiento no supervisado y el entrenamiento comparativo entre redes neuronales (MLP) y modelos de ensamble. Se permitirá el uso de librerías para los modelos de ensamble. Cabe resaltar que antes que resultados se evaluará su capacidad analítica para sortear las diferentes dificultades que presenta el caso.

Como entregable final, se requiere un informe técnico y (opcionalmente) una interfaz web informativa en Streamlit. Esta aplicación deberá simular la inferencia del modelo optimizado mediante escenarios precargados y aplicar políticas de mitigación de riesgos basadas en umbrales probabilísticos, demostrando el valor operativo de la solución propuesta.

2. Estándares Formales de Presentación

Para que el informe sea evaluado, cada equipo debe cumplir estrictamente con los siguientes requisitos de formato. El incumplimiento de cualquiera de estas normas penalizará la nota global del informe.

- **Extensión Máxima:** El cuerpo del informe no debe exceder las **10 páginas**, incluyendo figuras y tablas. Las referencias y el apéndice de coevaluación no cuentan en este límite.
- **Herramienta de Edición:** El documento debe ser redactado obligatoriamente en **LaTeX** utilizando esta plantilla. No se aceptarán entregas en Microsoft Word o Google Docs.
- **Estrategia Comunicativa (Estilo de Redacción):** Se debe emplear un tono estrictamente académico, en tercera persona y en tiempo pasivo impersonal (ej. *"se implementó el algoritmo X"* en lugar de *"diseñamos el modelo"*). Se valorará la capacidad de síntesis; los bloques redundantes o puramente descriptivos sin análisis crítico reducirán el puntaje.
- **Elementos Gráficos:** Todas las tablas y figuras deben estar numeradas, poseer una leyenda descriptiva autónoma (*caption*) y estar explícitamente citadas en el texto descriptivo anterior.

3. Estructura del Informe

El informe final debe estructurarse exactamente bajo las siguientes seis secciones académicas:

3.1. Resumen Ejecutivo e Introducción al Espacio Vectorial

1. **Definición del problema:** Explicación del problema de negocio e impacto ecológico detrás de la detección de especies acústicas. Descripción de la naturaleza matemática del dataset

tabular entregado (N observaciones con vectores de características $X \in \mathbb{R}^{64}$).

2. **Arquitectura del Pipeline:** Inclusión de un diagrama claro de arquitectura que ilustre el flujo completo de los datos, desde la ingesta del CSV hasta la inferencia final desplegada en la interfaz web de Streamlit. (La interfaz Streamlit es **opcional** y un bonus de 2 puntos sobre la entrega). Puede consultar el siguiente ejemplo https://youtu.be/LJ6DcLGQ4vY?si=dXSYU_vXXwuH60JG

3.2. Exploración Geométrica y Reducción de Dimensionalidad

1. **Análisis Comparativo:** Evaluación formal del desempeño de algoritmos lineales frente a no lineales. Se debe contrastar explícitamente el comportamiento de PCA contra aproximaciones de variedades múltiples como UMAP o t-SNE al proyectar las 64 dimensiones iniciales en espacios de visualización $2D$ o $3D$.
2. **Justificación Técnica:** Reporte cuantitativo que contraste el tiempo de ejecución de cada método frente a su capacidad para preservar la varianza global (en el caso de PCA) o las distancias geométricas locales (en UMAP/t-SNE).

3.3. Minería de Patrones y Estructuras de Clustering

1. **Segmentación Orgánica:** Implementación, definición de hiperparámetros y comparación analítica de al menos dos métodos de aprendizaje no supervisado basados en paradigmas distintos (ej. densidad con DBSCAN frente a modelos probabilísticos con Gaussian Mixture Models - GMM).
2. **Métricas de Validación:** Justificación matemática de la elección del número óptimo de clústeres descubiertos utilizando únicamente métricas implícitas, tales como el Coeficiente de Silhouette y los vistos en clase.

3.4. Arquitectura de Clasificación: MLP vs. Modelos de ensamble

1. **Diseño de la Red Neuronal:** Especificación matemática formal de la función de pérdida (*Loss Function*) empleada para la clasificación de especies. El reporte debe incluir una tabla detallando la topología de la red (número de capas ocultas, neuronas por capa y funciones de activación utilizadas).
2. **Estrategia de Regularización:** Análisis experimental que demuestre empíricamente el impacto de la posición relativa de las capas de *Dropout* y *Batch Normalization* sobre la estabilidad de las curvas de aprendizaje (Loss vs. Épocas).
3. **Benchmarking Computacional:** Comparación del modelo Multi-layer Perceptron (MLP) contra un modelo basado en árboles de decisión por gradiente (ej. XGBoost o LightGBM). La evaluación se sostendrá rigurosamente sobre la métrica F1-Score generalizada y el análisis exhaustivo de las matrices de confusión.

3.5. Decisiones de Ingeniería y Mitigación de Riesgos (MLOps & Negocio)

1. **Análisis de Trade-offs:** Discusión cualitativa o cuantitativa aproximada respecto al compromiso de diseño entre el costo computacional (estimación del tiempo de respuesta) y el rendimiento analítico en la calidad de clasificación del sistema.

- 2. Políticas de Moderación:** Propuesta de ingeniería para el diseño de umbrales operativos. Se debe proponer reglas de control basadas en el vector de probabilidades de salida para clasificar detecciones o aislar registros dudosos.

Estrategia Recomendada de Umbrales: Se sugiere estructurar la lógica de la interfaz web bajo tres estados operativos basados en la probabilidad predictiva (P):

- **Zona de Confianza** ($P \geq 85\%$): Clasificación automática. El sistema despliega una alerta visual verde confirmando la detección automática de la especie con alta fiabilidad.
- **Zona de Incertidumbre** ($40\% \leq P < 85\%$): Clasificación asistida. El sistema despliega una alerta visual amarilla catalogando el evento como dudoso y sugiriendo el envío del registro a una cola de auditoría por un experto humano.
- **Zona de Rechazo** ($P < 40\%$): Descarte automático. El evento es omitido por el software para mitigar el impacto del ruido ambiental.

3.6. Contribution statement

Para garantizar la equidad en el desarrollo grupal, cada equipo cerrará el informe incluyendo una réplica exacta de la siguiente tabla de coevaluación y asignación de roles en la sección de Anexos. Anexos no se contará para el recuento de páginas.

Nombre del Integrante	% Contribución	Tareas encargadas
1.	%	
2.	%	
3.	%	
4.	%	

Cuadro 1: Matriz de Coevaluación del Equipo de Desarrollo.

needspace

4. Rúbrica de Evaluación Analítica (Base de 20 Puntos)

La calificación del informe técnico se rige estrictamente por los siguientes criterios de rendimiento. El puntaje asignado a cada sección corresponde al nivel alcanzado de forma holística. Si un trabajo no cumple plenamente con las exigencias de un escalón específico, se le asignará el puntaje del nivel inmediato inferior.

Criterio 1: Resumen Ejecutivo e Introducción al Espacio Vectorial (Máximo: 3.0 puntos)

Puntaje	Indicadores de Rendimiento por Escalón
3.0 pts	Definición clara del problema de machine learning, la cual incluye un diagrama de arquitectura de su solución, que conecte el flujo desde la matriz base de características Mel hasta el despliegue informativo.
2.0 pts	Inclusión del diagrama de arquitectura y definición de las variables, pero abordados de forma puramente descriptiva, omitiendo la fundamentación del espacio vectorial de entrada.
1.0 pt	Presentación del diagrama de flujo incompleto o ambiguo, sin una descripción clara del problema de clasificación de señales eco-acústicas.
0.0 pts	Ausencia del diagrama de arquitectura o falta total de definición matemática del dataset.

Criterio 2: Exploración Geométrica y Reducción de Dimensionalidad (Máximo: 5 puntos)

Puntaje	Indicadores de Rendimiento por Escalón
5.0 pts	Comparación analítica y visual explícita de PCA frente a técnicas de variedades múltiples (UMAP o t-SNE) en espacios $2D$ o $3D$. Reporte formal de los tiempos de ejecución de cada método y justificación de la capacidad de retención de la estructura geométrica.
4.0 pts	Reducción dimensional ejecutada con dos métodos y presentación de gráficos correctos, pero con un reporte superficial de los tiempos de cómputo o de la varianza retenida.
2 pts	Aplicación de los algoritmos de reducción, pero limitando el reporte a la parte descriptiva visual de los gráficos, omitiendo los tiempos de ejecución y la comparación teórica de los métodos.
0.0 pts	Uso de un único método de reducción de dimensiones o ausencia total de visualizaciones en el reporte.

Criterio 3: Minería de Patrones y Estructuras de Clustering (Máximo: 5.0 puntos)

Puntaje	Indicadores de Rendimiento por Escalón
5.0 pts	Implementación y definición de hiperparámetros de al menos dos métodos de clustering basados en paradigmas distintos (ej. GMM vs DBSCAN). Justificación matemática rigurosa del número de grupos mediante el uso cruzado del Coeficiente de Silhouette y otras métricas del curso.
3.0 pts	Aplicación de dos modelos de clustering basados en paradigmas distintos, pero con un análisis descriptivo débil al momento de validar numéricamente los grupos encontrados.
2.5 pts	Segmentación ejecutada, pero omitiendo el contraste de hiperparámetros o seleccionando el número de clústeres de forma empírica sin el respaldo de métricas de validación interna.
0.0 pts	Procesamiento con un único algoritmo por defecto o elección totalmente arbitraria de los grupos.

Criterio 4: Arquitectura de Clasificación: MLP vs. Modelos de Ensamble (Máximo: 5.0 puntos)

Puntaje	Indicadores de Rendimiento por Escalón
5.0 pts	Especificación matemática formal de la Loss Function y topología detallada de la red. Análisis experimental de las curvas de aprendizaje (Loss vs. Épocas) evaluando Dropout y Batch Normalization. Comparación rigurosa del MLP vs Ensamblados usando F1-Score y matrices de confusión.
3.5 pts	Modelos construidos de forma funcional y comparados correctamente, pero con omisión de la formulación matemática de la Loss Function o con un análisis incompleto de la regularización en las curvas de aprendizaje.
2.0 pts	Comparación de modelos basada únicamente en la métrica de Accuracy general, ignorando el desbalance de clases y omitiendo el análisis detallado de las matrices de confusión o de las curvas de pérdida.
0.0 pts	Falta de claridad en la topología de la red, ausencia de técnicas de regularización o falta de la comparativa formal frente a modelos de ensamble.

Criterio 5: Decisiones de Ingeniería y Mitigación de Riesgos (Máximo: 2.0 puntos)

Puntaje	Indicadores de Rendimiento por Escalón
2 pts	Análisis analítico sobre el compromiso de diseño (<i>trade-off</i>) entre costo computacional aproximado y rendimiento analítico.
1 pts	Discusión de las implicancias de ingeniería para la presentación de resultados incorporando la propuesta de estados, pero omitiendo la evaluación del costo computacional del modelo.
0.5 pts	Descripción cualitativa o superficial de resultados, sin establecer reglas lógicas ni rangos probabilísticos claros para la moderación automática y el control de falsos positivos.
0.0 pts	Sección omitida o redactada con comentarios genéricos ajenos a la analítica predictiva del pipeline.

5. Políticas de Penalización

Se aplicarán sobre el entregable

Descripción	Puntaje Restado	Criterio
Entregar gráficas (<i>Pyplot/Seaborn/Matplotlib</i>) con tamaño de fuente en ejes o leyendas menor a 14 (<code>size < 14</code>).	-3.0 puntos	Inspección visual de las figuras insertadas en el PDF.
No incluir el enlace al repositorio de GitHub o que este se encuentre en estado privado / inaccesible.	-1.0 punto	Verificación del hipervínculo en la entrega de Canvas/Blackboard.
Entregar el informe sin la sección o la tabla completa de coevaluación (<i>Contribution Statement</i>).	-1.0 punto	Ausencia de la Sección 3.6 o filas vacías en la matriz.
Presentar un informe desordenado, que rompa la jerarquía de secciones establecida o que contenga texto superpuesto.	-1.0 punto	Desviación de la estructura obligatoria de este documento.
Documento excesivamente largo (Extensión mayor a 10 páginas impresas).	-1.0 punto	Conteo automático de páginas en el visualizador PDF.
Documento extremadamente corto o incompleto (Extensión total menor a 1 página).	-1.0 punto	Conteo automático de páginas en el visualizador PDF.
Incluir fragmentos de código fuente extensos explicados en el texto (en lugar de usar el repositorio).	-1.0 punto	Presencia de listings que superen las 15 líneas consecutivas de código.
Presencia de errores de compilación de LaTeX huérfanos (marcas de agua <i>¿?</i> por citas rotas).	-0.5 puntos	Detección de advertencias críticas de compilación en el log.

Cuadro 2: Tabla de penalizaciones.